



Departamento de Informática e Matemática Aplicada – DIMAp

Spring AI – Retrieval Augmented Generation (RAG)

Prof. Nélio Cacho

Universidade Federal do Rio Grande do Norte
neliocacho@dimap.ufrn.br

Hora de silenciar o celular...




- Manter o telefone celular sempre desligado/silencioso quando estiver em sala de aula;
- Nunca atender o celular na sala de aula.

O Desafio dos Modelos de Linguagem

- Limitações intrínsecas:
 - **Conhecimento estático:** Treinados com dados até uma data específica. Não acessam informações recentes.
 - **Alucinações:** Podem inventar fatos ou informações incorretas.
 - **Falta de especificidade:** Dificuldade em responder perguntas muito específicas ou de nicho sem ter visto esses dados durante o treinamento.


Como Melhorar a Resposta de Uma IA Generativa?



RAG: Retrieval Augmented Generation

- Combina o melhor de dois mundos:
 - Retrieval (Recuperação): Busca informações relevantes em uma base de dados externa (documentos, artigos, web).
 - Generation (Geração): Utiliza um LLM para gerar uma resposta contextualizada com base nas informações recuperadas.
 - Analogia: É como dar ao LLM a capacidade de "pesquisar no Google" antes de responder.

Como o RAG Funciona?



Como o RAG Funciona?

1. **Consulta do Usuário:** O usuário faz uma pergunta ou fornece um prompt.
2. **Recuperação (Retrieval):** Um sistema de busca encontra documentos ou trechos relevantes em uma base de dados externa **usando busca semântica**.
3. **Aumento (Augmentation):** Os trechos recuperados são passados para o LLM junto com a consulta original.
4. **Geração (Generation):** O LLM gera uma resposta informada pelos dados recuperados.

Por Que o RAG é Importante?

- **Atualização de Conhecimento:** Permite que os LLMs respondam com informações mais recentes.
- **Redução de Alucinações:** As respostas são "ancoradas" em fatos reais da base de conhecimento.
- **Maior Precisão e Especificidade:** Melhora a qualidade das respostas para perguntas de domínio específico.
- **Transparência:** É possível rastrear a fonte da informação na resposta.
- **Custo-benefício:** Não exige um novo treinamento massivo do LLM para cada nova informação.

Casos de Uso do RAG

- **Chatbots de Suporte ao Cliente:** Respostas precisas baseadas na documentação da empresa.
- **Sistemas de Perguntas e Respostas (Q&A):** Extração de informações de grandes volumes de texto.
- **Assistentes de Pesquisa:** Resumir e sintetizar informações de artigos científicos ou relatórios.
- **Geração de Conteúdo Informado:** Criar artigos ou resumos com dados factuais verificáveis.
- **Aplicações Jurídicas e Médicas:** Acesso rápido e preciso a informações regulatórias ou de pesquisa.

Ok, mas como funciona o RAG em detalhes?

- A parte de **Recuperação (Retrieval)** do RAG é baseada em busca semântica. Para realizar uma busca semântica é utilizado o conceito de **Embeddings**.


Embeddings: O Coração Numérico da Inteligência Artificial

- Um **embedding** é uma representação numérica (um vetor de números reais) de um item (como uma palavra, frase, documento, imagem, áudio ou qualquer outro tipo de dado) em um espaço de alta dimensão.
- A principal característica e o grande poder dos embeddings é que eles são construídos de forma que **itens com significados ou características semanticamente semelhantes estarão "próximos" uns dos outros nesse espaço vetorial.**

Visualização de um Embeddings

- Cada valor no array representa o quanto um conceito esta próximo do outro(+1) ou distante de outro (-1)

	living being	feline	human	gender	royalty	verb	plural
man →	0.6	-0.2	0.8	0.9	-0.1	-0.9	-0.7
woman →	0.7	0.3	0.8	-0.7	0.1	-0.5	-0.4
king →	0.5	-0.4	0.7	0.8	0.9	-0.7	-0.6
queen →	0.8	-0.1	0.8	-0.9	0.8	-0.5	-0.9
word	Word embedding						



Visualization of word embedding

Vamos supor esse exemplo:

- Imagine que eu queira convidar vocês para uma palestra minha que vai acontecer numa conferência, exe.: SBRC 2025.

Latitude	Longitude	Data/Hora	Sala
----------	-----------	-----------	------

- Cada característica dessas pode ser representado por um número:

-5.841938888119346	-35.182044737489626	210520250845	5
--------------------	---------------------	--------------	---

- Geralmente esses dados são normalizados(entre 1 e -1):

-0.25142547	-0.14575421	0.7458214574	0.25
-------------	-------------	--------------	------

Isso gera um Vetor de Números:

- Vetor de Números: Imagine uma lista longa de números (por exemplo, $[0.123, -0.456, 0.789, \dots, 0.054]$).
- Cada número nesse vetor pode ser pensado como uma "característica" ou um "atributo" latente do item que ele representa.
- Espaço Vetorial de Alta Dimensão: Esses vetores vivem em um espaço onde cada número do vetor é uma dimensão.
- "Alta dimensão" significa que esses vetores podem ter centenas ou milhares de números, ou seja, vivem em espaços com centenas ou milhares de dimensões.


Latitude	Longitude	Data/Hora	Sala	Tema	Num. Parti
----------	-----------	-----------	------	------	------------

Vamos supor esse exemplo:

- **Captura de Significado:** A mágica está no processo de criação.
- Os algoritmos que geram embeddings aprendem a mapear dados complexos para esses vetores numéricos de tal forma que a similaridade de significado ou característica se traduz em proximidade geométrica nesse espaço vetorial.
- Exemplo: No contexto de palavras, o embedding de "rei" estará próximo ao de "rainha" e "homem", mas distante de "felino" ou "verbo".

Semantic Space

- Modelos de IA geralmente representam conceitos em “semantic space”.
 - Similar a coordenadas geométricas
 - Permite que modelos possam determinar o quanto próximo um conceito é do outro.



Semantic Search

- Baseado no Semantic Space, é possível desenvolver busca semântica.
- O que é busca semântica?
 - A **consulta semântica** é uma forma avançada de busca que vai além da simples correspondência de palavras-chave.
 - Em vez de procurar por termos exatos ou variações literais, ela foca em compreender o **significado e a intenção** por trás da pergunta do usuário.
 - O objetivo é retornar resultados que são semanticamente **relevantes**, mesmo que não contenham as palavras exatas da consulta.

Keyword Search vs Semantic Search

- Suponha que um aluno do Ensino médio deseja achar um curso de interesse com base em palavras chaves. Se for usada a palavra chave “salvar vidas” esse curso abaixo seria selecionado?

“Medicina: Formação Generalista e Humanista: Foco em capacitar o profissional para atuar em diversas áreas da medicina, com forte ênfase na atenção primária, saúde coletiva e aspectos éticos e sociais da profissão. Longa Duração e Intensidade: É um curso integral de 6 anos, com alta carga horária teórica e prática. Prática Clínica e Estágios: Inclui estágios supervisionados em hospitais (como o Hospital Universitário Onofre Lopes - HUOL), unidades de saúde e outros cenários de prática desde os primeiros anos. Pesquisa: Incentivo à participação em projetos de iniciação científica e ligas acadêmicas. Alta Concorrência: Historicamente um dos cursos mais disputados no SiSU.”

Semantic Search


- O processo de Busca Semântica é realizado em duas etapas:
 - **Vetorização do Conteúdo:** Documentos, artigos, produtos, imagens (ou qualquer item que possa ser pesquisado) também são pré-processados e transformados em seus respectivos **vetores de embedding**. Esses vetores são armazenados em um **banco de dados vetorial**.
 - **Vetorização da Consulta:** A pergunta ou frase de busca do usuário é transformada em um **vetor de embedding** usando um modelo de linguagem (LLM) ou um modelo de embedding dedicado.

Vetorização do Conteúdo

“Medicina: Formação Generalista e Humanista: Foco em capacitar o profissional para atuar em diversas áreas da medicina, com forte ênfase na atenção primária, saúde coletiva e aspectos éticos e sociais da profissão. Longa Duração e Intensidade: É um curso integral de 6 anos, com alta carga horária teórica e prática. Prática Clínica e Estágios: Inclui estágios supervisionados em hospitais (como o Hospital Universitário Onofre Lopes - HUOL), unidades de saúde e outros cenários de prática desde os primeiros anos. Pesquisa: Incentivo à participação em projetos de iniciação científica e ligas acadêmicas. Alta Concorrência: Historicamente um dos cursos mais disputados no SiSU.”

Ciência da Computação: Fundamentos Teóricos e Práticos: Abrange algoritmos, estruturas de dados, linguagens de programação, arquitetura de computadores, sistemas operacionais, redes e inteligência artificial. Pensamento Computacional: Desenvolvimento da capacidade de resolver problemas de forma lógica e eficiente, usando ferramentas computacionais. Desenvolvimento de Software e Hardware: Prepara para atuar no desenvolvimento de sistemas, softwares, jogos, aplicativos, segurança da informação, entre outros. Inovação e Pesquisa: Fortemente voltado para a pesquisa e inovação, com possibilidades de atuação em polos tecnológicos e instituições de P&D. Duração: Aproximadamente 4 a 4,5 anos (bacharelado). A UFRN também oferece o Bacharelado em Tecnologia da Informação (BTI) como um ciclo inicial para Ciência da Computação, Engenharia de Software e Engenharia de Computação."

(1) Fornecer o texto



Embedding Model

(2) Gerar o Embedding

(3) Salvar num Repositório(BD)




[illegible]

Vetorização da Consulta

- O texto é convertido em um embeddings e enviado para o sistema de busca, que não procura por palavras-chave.
- Em vez disso, ele encontra os embeddings no banco de dados vetorial que são geometricamente mais próximos do embedding da consulta.
- Essa proximidade significa similaridade de significado.
- Os itens cujos embeddings são os mais próximos (semanticamente mais similares) são retornados como resultados da busca.
- Existem várias técnicas de busca vetorial (Vizinho Mais Próximo Exato – KNN, Vizinho Mais Próximo Aproximado – ANN, Similaridade de Cosseno, etc).

Similaridade de Coseno


- Sabemos que o valor do cosseno entre dois ângulos é um número que varia entre -1 e 1. Quando o ângulo entre eles se aproxima de 0° , o cosseno se aproxima de 1. Já quando os vetores são ortogonais (ou seja, ângulo de 90°), o cosseno é igual a 0. E, por fim, quando os vetores são opostos, o cosseno se aproxima de -1.
- Assim, podemos considerar que cosseno próximo de 1 indica uma grande similaridade entre os vetores, enquanto que cosseno próximo de -1 indica o oposto.



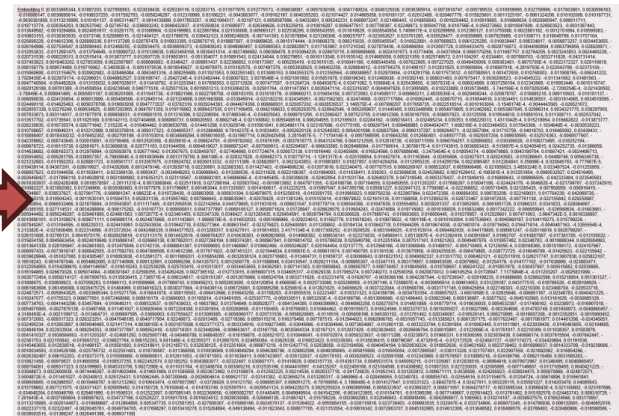
Como realizar uma consulta semântica ?




(4) O texto da consulta (exe.: “Salvar vidas”) é vetorizado



Embedding
Model



(5) Aplica Similaridade de Coseno com os embeddings salvos



“Medicina: Formação Generalista e Humanista: Foco em capacitar o profissional para atuar em diversas áreas da medicina, com forte ênfase na atenção primária, saúde coletiva e aspectos éticos e sociais da profissão. Longa Duração e Intensidade: É um curso integral de 6 anos, com alta carga horária teórica e prática. Prática Clínica e Estágios: Inclui estágios supervisionados em hospitais (como o Hospital Universitário Onofre Lopes - HUOL), unidades de saúde e outros cenários de prática desde os primeiros anos. Pesquisa: Incentivo à participação em projetos de iniciação científica e ligas acadêmicas. Alta Concorrência: Historicamente um dos cursos mais disputados no SiSU.”

Como implementar isso no Spring?

- Configure seu application.yml, habilitando o modelo de embeddings.

```
spring:
  application.name: embedding-service

  ai:
    retry:
      max-attempts: 1
---
spring:
  config.activate.on-profile: openai
  ai:
    openai:
      api-key: sk-proj-E--MH_cBp-q6e4DODRs2V_gLME_ssJME1rXzUzj0qwcC
      embedding:
        enabled: true
        options:
          model: text-embedding-ada-002
```


Como implementar isso no Spring?

```
← EmbeddingService
@RestController
public class EmbeddingController {
    private final EmbeddingService embeddingService;

    ← EmbeddingService
    public EmbeddingController(EmbeddingService embeddingService) {
        this.embeddingService = embeddingService;
    }
    http://127.0.0.1:8080/embedding
    @GetMapping("embedding")
    public String getResposta(@RequestParam String pergunta) {
        return embeddingService.findCurso(pergunta);
    }
}
```

Como implementar isso no Spring?

→ EmbeddingController | ← OpenAiEmbeddingModel

```
@Service
public class EmbeddingService {

    private final EmbeddingModel model;

    private List<String> cursos = List.of(
        "Medicina: Formação Generalista e Humanista: Foco em capacitar o profissional para atuar em diversas áreas da medicina, com Longa Duração e Intensidade: É um curso integral de 6 anos, com alta carga horária teórica e prática. Prática Clínica e Estágios: Inclui estágios supervisionados em hospitais (como o Hospital Universitário). Pesquisa: Incentivo à participação em projetos de iniciação científica e ligas acadêmicas.\n" + //
        "Alta Concorrência: Historicamente um dos cursos mais disputados no SiSU.",
        "Direito: Formação em Ciências Jurídicas e Sociais: Aborda os fundamentos do direito (constitucional, civil, penal, administrativo). Múltiplas Áreas de Atuação: Prepara para a advocacia, magistratura, Ministério Público, defensoria pública. Habilidades Críticas e Argumentativas: Desenvolvimento da capacidade de análise, interpretação de leis. Pesquisa e Extensão: Incentivo à pesquisa em diversas áreas do direito e participação em projetos de pesquisa. Duração: 5 anos (bacharelado).",
        "Engenharia Elétrica: Formação Abrangente em Eletricidade: Foco em sistemas de potência (geração, transmissão e distribuição). Base Sólida em Exatas: Grande ênfase em matemática, física e computação.\n" + //
        "Habilidades Analíticas e de Projeto: Capacidade de conceber, projetar, implementar e manter sistemas. Atuação Diversificada: Campo de trabalho em indústrias, empresas de energia, telecomunicações, automação. Duração: 5 anos (bacharelado).",
        "Ciência da Computação: Fundamentos Teóricos e Práticos: Abrange algoritmos, estruturas de dados, linguagens de programação. Pensamento Computacional: Desenvolvimento da capacidade de resolver problemas de forma lógica e eficiente. Desenvolvimento de Software e Hardware: Prepara para atuar no desenvolvimento de sistemas, softwares, aplicativos. Inovação e Pesquisa: Fortemente voltado para a pesquisa e inovação, com possibilidades de atuação em diversas áreas. Duração: Aproximadamente 4 a 4,5 anos (bacharelado). A UFRN também oferece o Bacharelado em Tecnologia da Informação."
    );

    public EmbeddingService(EmbeddingModel model) { ... }
    public String findCurso(String query) { ... }
    public static int findColosestMatch(float[] query, List<float[]> cursos) { ... }
    public static double cosineSimilarity(float[] vectorA, float[] vectorB) { ... }
}
```

Como implementar isso no Spring?

```
public EmbeddingService(EmbeddingModel model) {
    this.model = model;
}

public String findCurso(String query) {

    List<float[]> cursoEmbeddings = null;
    float[] queryEmbedding = null;

    cursoEmbeddings = model.embed(cursos); // Embedding dos cursos
    queryEmbedding = model.embed(query); // Embedding da query

    int mostSimilarIndex = -1;
    mostSimilarIndex = findColosestMatch(queryEmbedding, cursoEmbeddings); //

    if(mostSimilarIndex < 0) {
        return "Nenhum curso encontrado para a consulta: " + query;
    } else {
        return cursos.get(mostSimilarIndex);
    }
}

public static int findColosestMatch(float[] query, List<float[]> cursos) { ...
public static double cosineSimilarity(float[] vectorA, float[] vectorB) { ...
```



```
} }
```

Resultado

← → ↻ localhost:8080/embedding?pergunta=salvar vidas

Medicina: Formação Generalista e Humanista: medicina, com forte ênfase na atenção primária.
Duração e Intensidade: É um curso integral de 6 anos.
Estágios: Inclui estágios supervisionados em hospitais, unidades de saúde e outros cenários de prática clínica, além de projetos de iniciação científica e ligas acadêmicas disputados no SiSU.

← → ↻ localhost:8080/embedding?pergunta=burocracia

Direito: Formação em Ciências Jurídicas e Administrativas: Direito, Direito Administrativo, Direito Constitucional, Direito Civil, Direito do Trabalho, Direito Penal, Direito Processual Civil, Direito Processual Penal, Direito Tributário, Direito Urbanístico, etc.), a teoria do Estado e a administração pública, a advocacia, magistratura, Ministério Público, órgãos públicos, entre outros. Habilidades: interpretação de leis, argumentação e escrita jurídica, participação em projetos de extensão e pesquisa.
Duração: 5 anos (bacharelado).

← → ↻ localhost:8080/embedding?pergunta=web

Ciência da Computação: Fundamentos Técnicos e Programação: Fundamentos de programação, arquitetura de computadores, sistemas operacionais, redes de computadores, banco de dados, programação orientada a objetos, etc.
Computacional: Desenvolvimento de Software: Desenvolvimento de sistemas, softwares, jogos, aplicativos, segurança da informação, etc.
Duração: Aproximadamente 4 a 4,5 anos (bacharelado).
Informação (BTI) como um ciclo inicial para a Computação.

Vector Store

- O termo **Vector Store** (ou **Banco de Dados Vetorial**, que são sinônimos e os termos são frequentemente usados de forma intercambiável) refere-se a um tipo especializado de banco de dados otimizado para armazenar, indexar e consultar **vetores de alta dimensão**.
- Sua principal funcionalidade é permitir a **busca por similaridade semântica**, em vez da busca tradicional por palavras-chave ou correspondência exata.



Usando Vector Store no Spring

```
<dependency>  
  <groupId>org.springframework.ai</groupId>  
  <artifactId>spring-ai-vector-store</artifactId>  
</dependency>
```

Criando um Bean para o VectorStore

```
@SpringBootApplication
public class EmbeddingApplication {

    Run | Debug
    public static void main(String[] args) {
        SpringApplication.run(primarySource:EmbeddingApplication.class, args);
    }
    @Bean
    public VectorStore vectorStore(EmbeddingModel embeddingModel) {
        return SimpleVectorStore.builder(embeddingModel).build();
    }
}
```

Criando uma Interface para o DAO

```
public interface CursosDAO {  
    void add(List<String> cursos);  
    List<String> findClosestMatches(String query,int numberOfMatches);  
    String findClosestMatch(String query);  
}
```


Implementando o DAO

```
@Repository
public class CursosDAOImpl implements CursosDAO {
    @Autowired VectorStore vectorStore;
    public void add(List<String> cursos) {
        List<Document> documents = cursos.stream()
            .map(Document::new)
            .toList();
        vectorStore.add(documents);
    }
    public List<String> findClosestMatches(String query, int numberOfMatches) {
        SearchRequest request = SearchRequest.builder()
            .query(query)
            .topK(numberOfMatches)
            .build();
        List<Document> results = vectorStore.similaritySearch(request);
        if (results == null) {
            return List.of();
        }
        return results.stream()
            .map((Document doc) -> doc.getText())
            .toList();
    }
    public String findClosestMatch(String query) {
        return findClosestMatches(query, numberOfMatches:1).get(index:0);
    }
}
```

Definindo uma interface para o Service

```
public interface CursosService {  
    void save(List<String> cursos);  
    List<String> findClosestMatches(String query);  
    String findClosestMatch(String query);  
}
```


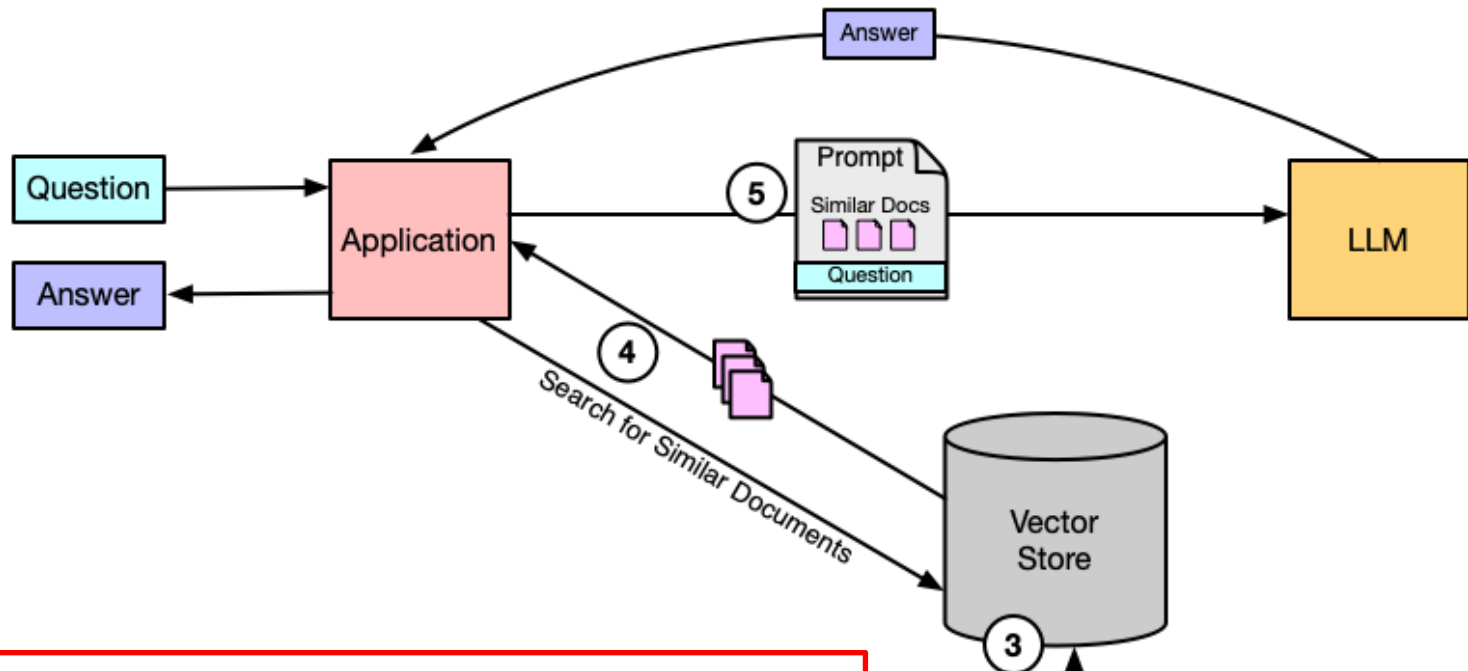
Implementando o Service

```
@Service
public class CursosServiceImpl implements CursosService {
    private final CursosDAO cursosDAO;
    public CursosServiceImpl(CursosDAO cursosDAO) {
        this.cursosDAO = cursosDAO;
    }
    @Override
    public void save(List<String> cursos) {
        cursosDAO.add(cursos);
    }
    @Override
    public List<String> findClosestMatches(String query) {
        return cursosDAO.findClosestMatches(query, numberOfMatches:5);
    }
    @Override
    public String findClosestMatch(String query) {
        return cursosDAO.findClosestMatch(query);
    }
}
```


Implementando o Controller

```
public EmbeddingController(CursosServiceImpl embeddingService) {  
    this.embeddingService = embeddingService;  
}  
  
@GetMapping("embedding")  
public String getResposta(@RequestParam String pergunta) {  
    return embeddingService.findClosestMatch(pergunta);  
}  
  
@GetMapping("addcurso")  
public void getResposta() {  
    embeddingService.save(cursos);  
}
```

Lembrando do fluxo completo...



Vamos Importar os Documentos para o Vector Store



Lendo os Arquivos...

- O Spring AI oferece diversos leitores de documentos, todos baseados na interface *DocumentReader*.
- Os leitores inclusos no módulo core do Spring AI são:
 - TextReader: Para leitura de arquivos de texto simples.
 - JsonReader: Para leitura de arquivos JSON.
 - No entanto, para carregar arquivos mais complexos como PDF, que geralmente não estão em formatos de texto simples ou JSON, é necessário considerar outras opções de leitores de documentos do Spring AI.

Lendo os Arquivos...

- O Spring AI oferece leitores específicos para arquivos PDF:
 - *PagePdfDocumentReader*: Lê PDFs, dividindo-os em múltiplos documentos a cada quebra de página.
 - *ParagraphPdfDocumentReader*: Lê PDFs, dividindo-os por parágrafo (definido livremente como uma seção no sumário do documento).
- Ambos dividem documentos em pedaços menores. Enquanto o *PagePdfDocumentReader* divide por quebras de página, o *ParagraphPdfDocumentReader* depende da existência de metadados de sumário no PDF, dividindo o documento por seções.
- Apesar de sua definição peculiar de parágrafo, o *ParagraphPdfDocumentReader* pode não ser adequado para todos os PDFs, especialmente se o documento não incluir metadados de sumário, o que causaria uma exceção

Lendo os Arquivos...

- Para situações que exigem flexibilidade no tipo de documento a ser carregado, considere o TikaDocumentReader do Spring AI.
- Este leitor, baseado no Apache Tika, é capaz de ler uma vasta seleção de tipos de documentos, incluindo:
 - Arquivos de texto simples
 - Arquivos JSON
 - Arquivos PDF
 - Documentos do Microsoft Word
 - E muitos outros formatos, como planilhas, apresentações e imagens com texto.
- O TikaDocumentReader se torna a ferramenta ideal quando a origem dos dados é variada e não se limita a um único tipo de arquivo, garantindo uma ingestão de dados mais abrangente para seu pipeline de IA.

Usando o TikaDocumentReader

- Para usar o TikaDocumentReader, deve-se importar a seguinte biblioteca no seu arquivo pom.xml:

```
<dependency>
  <groupId>org.springframework.ai</groupId>
  <artifactId>spring-ai-tika-document-reader</artifactId>
  <version>1.0.0</version>
</dependency>
```

Usando o TikaDocumentReader


```
@Component
class DocumentReader {

    private final Resource resource;

    DocumentReader() {
        String filePath = "C:/Users/nelio/Documents/Regulamentograd.pdf";
        this.resource = new FileSystemResource(filePath);
    }

    List<Document> loadText() {
        TikaDocumentReader tikaDocumentReader = new TikaDocumentReader(this.resource);
        return tikaDocumentReader.read();
    }
}
```

Vamos dividir o documento em chunks



Divisão de Documentos para LLMs

- Documentos extensos precisam ser divididos em pedaços menores para evitar que todo o conteúdo seja enviado como contexto em um único prompt para o LLM.
- Leitores de PDF do Spring AI já realizam essa divisão automaticamente.
- No entanto, ao usar o TikaDocumentReader (que não divide documentos por padrão), é necessário um divisor de documentos no pipeline de carregamento.

Divisão de Documentos para LLMs

- O Spring AI fornece um divisor de texto em tokens.
- O ***TokenTextSplitter*** é uma classe que realiza a divisão de texto que opera com base na contagem de tokens, e não na contagem de caracteres.
- Ela utiliza um codificador (encoder) específico para um LLM (como o tiktoken para modelos OpenAI) para contar e dividir o texto exatamente como o modelo o faria.
- Isso permite um controle preciso sobre o tamanho dos chunks em termos de tokens.

Divisão de Documentos para LLMs

```
@Override
public void loadDocument() {
    List<Document> documents = documentReader.loadText();
    TokenTextSplitter splitter = new TokenTextSplitter();
    List<Document> chucksdocs = splitter.apply(documents);
    // Adiciona os documentos ao VectorStore
    cursosDAO.add(chucksdocs);
}
```

Salvamento dos chunks no Vector Store

```
@Repository
public class CursosDAOImpl implements CursosDAO {
    @Autowired VectorStore vectorStore;

    public void add(List<Document> chunks) {
        vectorStore.add(chunks);
    }
}
```


```
@Override
public void loadDocument() {
    List<Document> documents = documentReader.loadText();
    TokenTextSplitter splitter = new TokenTextSplitter();
    List<Document> chunksdocs = splitter.apply(documents);
    // Adiciona os documentos ao VectorStore
    cursosDAO.add(chunksdocs);
}
```


Adicionando Regras ao Vector Store

```
http://127.0.0.1:8080/addregras (Count=1 Total=69,38s Max=0,00s)
@GetMapping("addregras")
public void getResposta() {
    embeddingService.loadDocument();
}
```

```
2025-05-29T15:56:27.233-03:00 INFO 16256 --- [embedding-service] [nio-8080-exec-1] o.s.a.transformer.splitter.TextSplitter : Splitting up document into 93 chunks.
2025-05-29T15:56:29.255-03:00 INFO 16256 --- [embedding-service] [nio-8080-exec-1] o.s.ai.vectorstore.SimpleVectorStore : Calling EmbeddingModel for document id = 619b2b14-54ee-4602-8b27-35faeb61881a
2025-05-29T15:56:29.592-03:00 INFO 16256 --- [embedding-service] [nio-8080-exec-1] o.s.ai.vectorstore.SimpleVectorStore : Calling EmbeddingModel for document id = 5d270274-282b-4855-916d-b1b000c1e24a
2025-05-29T15:56:30.286-03:00 INFO 16256 --- [embedding-service] [nio-8080-exec-1] o.s.ai.vectorstore.SimpleVectorStore : Calling EmbeddingModel for document id = bef6bf60-bf8e-4add-a5dc-
```

Realizando a Parte de Generation do RAG



Realizando a parte de Generation

- Após a recuperação de informações relevantes (fase de Retrieval), o objetivo é sintetizar essas informações e a pergunta original.
- Gerar uma resposta final, fluida, precisa e que diretamente aborde a pergunta do usuário.

Realizando a parte de Generation

- Um LLM é o componente central desta fase.
- Ele recebe como entrada combinada:
 - A **pergunta original** do usuário.
 - Os **chunks de contexto** recuperados (passados como parte do prompt).
- O LLM utiliza seu vasto conhecimento pré-treinado e a informação contextual fornecida para formular a resposta.

Realizando a parte de Generation

- O LLM processa o prompt completo e os chunks de contexto.
- Identifica as partes mais relevantes do contexto que respondem à pergunta.
- Reorganiza e reescreve essas informações de forma natural e gramaticalmente correta.
- Adapta o tom e o estilo da resposta de acordo com as instruções do prompt.

Como estava o código para realizar a pergunta a LLM?

```
@Override
public String getResposta(String pergunta) {
    return chatClient.prompt()
        .system(systemSpec -> systemSpec
            .text(templateSystem)
            .param(k:"Universidade", v:"UFRN"))
        .user(userSpec -> userSpec
            .text(templateUser)
            .param(k:"Pergunta", pergunta))
        .call()
        .content();
}
```

Para adicionar o Generation do RAG faço:

```
@Override
public String getResposta(String pergunta) {
    return chatClient.prompt()
        .advisors(new QuestionAnswerAdvisor(vectorStore))

        .system(systemSpec -> systemSpec
            .text(templatesystem)
            .param(k:"Universidade", v:"UFRN"))
        .user(userSpec -> userSpec
            .text(templateuser)
            .param(k:"Pergunta", pergunta))
        .call()
        .content();
}
```

Advisors

- A API de Advisors do Spring AI oferece uma maneira flexível e poderosa de interceptar, modificar e aprimorar interações impulsionadas por IA em suas aplicações Spring.
- **Benefícios Chave da API de Advisors**
 - **Encapsulamento de Padrões:** Encapsula padrões recorrentes de IA Generativa.
 - **Transformação de Dados:** Transforma dados enviados para recebidos de Large Language Models (LLMs).
 - **Portabilidade:** Proporciona portabilidade entre vários modelos e casos de uso.

QuestionAnswerAdvisor

- **A Conexão com o Banco de Dados Vetorial:** Quando uma pergunta do usuário é enviada ao modelo de IA, o **QuestionAnswerAdvisor** consulta este banco de dados vetorial em busca de documentos relacionados à pergunta.
- **Fornecendo Contexto ao LLM:** A resposta do banco de dados vetorial é anexada ao texto do usuário para fornecer contexto para o modelo de IA gerar uma resposta.

Consulta usando apenas o Vector Store

← → ↺ ⓘ localhost:8080/embedding?pergunta=qual%20a%20regra%20para%20reprovação?

🔍 ☆ 🔄 📄 🌐 ⋮

relacionados aos conteúdos de cada uma das unidades. §3º Não há mecanismo de reposição de nota para o estudante que não comparece à avaliação de reposição. Art. 117. O estudante que realiza avaliação de reposição é considerado aprovado, quanto à avaliação do rendimento acadêmico, caso obtenha média final igual ou superior a 5,0 (cinco), com rendimento acadêmico igual ou superior a 4,0 (quatro) na avaliação de reposição. Art. 118. O prazo para realização da avaliação de reposição é de, no mínimo, 3 (três) dias letivos, contados a partir da divulgação da média parcial e da frequência do estudante no sistema de gestão acadêmica. Art. 119. Não deve ser realizada avaliação de reposição sem que a média parcial e a frequência dos estudantes tenham sido cadastradas no sistema de gestão acadêmica, sob pena de a referida avaliação ser anulada. §1º O pedido de anulação da avaliação pode ser realizado por qualquer estudante da turma, devendo ser protocolado na unidade acadêmica a qual o componente curricular é vinculado, no prazo máximo de até 1 (um) dia útil após a realização da atividade. §2º Compete à chefia da unidade acadêmica avaliar o pedido de anulação da atividade e, sendo constatado que as condições previstas no caput deste artigo não tenham sido cumpridas, determinar a anulação da atividade e a publicação imediata da média parcial e da frequência dos estudantes. Art. 120. O critério de assiduidade em uma disciplina presencial é satisfeito quando o estudante cumpre a frequência mínima correspondente a 75% (setenta e cinco por cento) da carga horária do componente curricular, considerando o rendimento acadêmico exigido. Art. 121. É permitido ao estudante,

Consulta usando RAG

← → ↺ localhost:8080/consulta?pergunta=qual%20a%20regra%20para%20reprova%3F



Respirando fundo, vamos responder sua dúvida: qual a regra para reprovação na UFRN? A regra de reprovação pode ser dividida em dois principais critérios: rendimento acadêmico (nota) e assiduidade (frequência). Veja abaixo o passo a passo para entender melhor: ****1. Frequência (Assiduidade)**** - É necessário cumprir, no mínimo, 75% de presença nas aulas da disciplina. - Se o estudante não atingir esse percentual de frequência, será reprovado por falta, independentemente da nota. ****2. Nota (Rendimento Acadêmico)**** - A média final deve ser igual ou superior a 6,0 (seis) e o rendimento em cada unidade (provas/avaliações) deve ser igual ou superior a 4,0 (quatro). - Se o estudante não atingir esses critérios, pode ter direito a uma avaliação de reposição, desde que: - Tenha frequência mínima de 75%. - Tenha média parcial igual ou superior a 3,0. ****3. Avaliação de Reposição**** - Se após a avaliação de reposição, a média final for igual ou superior a 5,0, com nota igual ou superior a 4,0 na reposição, o estudante é

Consulta usando RAG

localhost:8080/consulta?pergunta=como+devo+solicitar+o+trancamento+de+um+curso



Como solicitar o trancamento de curso na UFRN

Trancamento de curso não está detalhado no contexto fornecido, mas com base nas informações, o que existe é o **cancelamento de curso** e o **trancamento de matrícula em disciplina ou bloco**.

Trancamento de matrícula em disciplina ou bloco

- Você pode solicitar o trancamento de matrícula em uma disciplina ou bloco até o prazo de 1/3 da carga horária da disciplina.
- O trancamento só pode ser feito uma vez por componente curricular.
- Após a solicitação, o trancamento só é efetivado depois de 2 dias, período no qual pode ser desistido.
- Atividades que não formam turma não podem ser trancadas.

Trancamento de curso

O contexto não detalha o procedimento para trancamento total do curso, apenas sobre **cancelamento de curso** (quando o estudante se desliga definitivamente da graduação, por interesse pessoal ou outros motivos).

Se você deseja **suspender temporariamente** o vínculo com o curso (trancamento total), recomendo que entre em contato com a coordenação do seu curso ou consulte o sistema acadêmico (SIGAA), pois o regulamento citado não traz os passos para esta solicitação.

Resumo:

- Para trancar uma disciplina ou bloco, faça a solicitação até 1/3 da carga horária no SIGAA.
- Trancamento total do curso (suspensão) não está especificado no contexto fornecido.
- Cancelamento de curso é o desligamento definitivo, e pode ser solicitado por interesse pessoal mediante quitação com a UFRN.

Dica: Consulte a coordenação do seu curso para orientação sobre trancamento total de curso, caso essa seja sua necessidade.

Tem outra dúvida? Pergunte aqui:

Digite sua dúvida...

Enviar pergunta