



Departamento de Informática e Matemática Aplicada – DIMAp

Spring AI – Model Context Protocol (MCP)

Prof. Nélio Cacho


Universidade Federal do Rio Grande do Norte
neliocacho@dimap.ufrn.br

Hora de silenciar o celular...




- Manter o telefone celular sempre desligado/silencioso quando estiver em sala de aula;
- Nunca atender o celular na sala de aula.

Na aula passada...



Na aula passada, esse Tool (em vermelho) foi definido na aplicação do nosso *chatbot* para adicionar funcionalidades de operação junto ao Sigaa. No entanto, toda a regra de negócio de chamada foi acoplada ao chatbot. Se para toda funcionalidade externa, for necessário fazer algo parecido, seria necessário colocar um grande volume de código acoplado aos serviços que usam LLM.

Nossa arquitetura na aula passada....



Problemas na Interação entre Modelos

- A forma como os LLMs se comunicavam com bases de dados, sistemas de arquivos, APIs e outras ferramentas era muitas vezes ad-hoc, dependendo da implementação específica de cada modelo ou plataforma. Isso gerava uma série de desafios:
 - **Fragmentação e Incompatibilidade:** Cada LLM ou plataforma poderia ter sua própria maneira de "chamar" ou "usar" ferramentas, tornando difícil a interoperabilidade. Um desenvolvedor precisaria adaptar seu código para cada LLM que desejasse usar, o que aumentava a complexidade e o tempo de desenvolvimento.
 - **Gestão de Contexto:** Garantir que o LLM tivesse acesso às informações corretas sobre as ferramentas disponíveis e como utilizá-las (o "contexto" da ferramenta) era um desafio.
 - **Comunicação Bidirecional:** A troca de informações (requisições para a ferramenta e respostas da ferramenta para o LLM) precisava ser robusta e flexível, suportando diferentes tipos de dados e padrões de comunicação.
 - **Escalabilidade:** Com o crescimento do número de LLMs e a diversidade de ferramentas, a falta de um protocolo padrão dificultava a escalabilidade e a reutilização de componentes.

Model Context Protocol (MCP)

- O **Model Context Protocol** (MCP) é um protocolo padronizado que permite aos modelos de IA interagir com ferramentas e recursos externos de forma estruturada. Ele suporta múltiplos mecanismos de transporte para oferecer flexibilidade em diferentes ambientes.
- O **Model Context Protocol** (MCP) foi especificado recentemente em Novembro de 2024 pela **Anthropic** (os criadores da família de modelos Claude).
- Apesar de ter sido definida pela Anthropic, ela pode ser usada com qualquer **LLM** (Large Language Model) e **API** que suporte tools, incluindo os modelos OpenAI.

Model Context Protocol (MCP)

- Os dois componentes principais do MCP são os **Servidores MCP** e os **Cientes MCP**.
- Um **Servidor MCP** tem acesso a algum recurso, como um banco de dados, sistema de arquivos ou API, e expõe o acesso a esse recurso por meio de uma ou mais ferramentas.
- Um **Cliente MCP** rodando dentro de uma aplicação se comunica com o Servidor MCP, buscando uma lista de suas ferramentas, disponibilizando essas ferramentas no contexto de um *prompt* e invocando essas ferramentas em nome do LLM.

Model Context Protocol (MCP)

- Já existem centenas de milhares de MCP Servers disponíveis.

The screenshot shows the homepage of mcpservers.org. The browser address bar displays 'mcpservers.org'. The website header includes a navigation menu with 'MCP Servers', 'Home', 'Remote Servers', and 'Resources'. On the right, there are links for 'ChatHub' and a 'Submit' button. A banner for 'New: Remote MCP Servers' is visible. The main heading is 'Awesome MCP Servers', followed by the subtitle 'A collection of servers for the Model Context Protocol.' Below this is a filter bar with categories: 'All', 'Official', 'Search', 'Web Scraping', 'Communication', 'Productivity', 'Development', 'Database', 'Cloud Service', 'File System', 'Cloud Storage', 'Version Control', and 'Other'. The main content area displays several server cards, each with a title, description, and a 'View Details' button. The cards shown are: 'Bright Data' (marked as a sponsor), 'Brave Search', 'Fetch', 'Filesystem', 'Git', 'GitLab', 'STARLINK' (with a note about speed and price), and 'Google Drive'.

mcpservers.org

MCP Servers Home Remote Servers Resources ChatHub Submit

New: Remote MCP Servers

Awesome MCP Servers

A collection of servers for the Model Context Protocol.

All Official Search Web Scraping Communication Productivity Development Database Cloud Service File System Cloud Storage Version Control Other

Bright Data sponsor

Discover, extract, and interact with the web - one interface powering automated access across the public internet.

View Details

Brave Search

Web and local search using Brave's Search API

View Details

Fetch

Web content fetching and conversion for efficient LLM usage

View Details

Filesystem

Secure file operations with configurable access controls

View Details

Git

Tools to read, search, and manipulate Git repositories

GitLab

GitLab API, enabling project management


STARLINK

Velocidades de até 250+ Mbps,
R\$ 1.439 (20% de desconto sobre o preço) pela Kit Starlink Mini

Google Drive


File access and search capabilities for Google Drive

Model Context Protocol (MCP)



Model Context Protocol (MCP)

- [MCP Java SDK](#) oferece uma implementação em Java do Model Context Protocol, permitindo a interação padronizada com modelos e ferramentas de IA por meio de padrões de comunicação síncronos e assíncronos.




Model Context Protocol (MCP) no Spring

- O **MCP Java SDK** segue uma arquitetura em camadas com clara separação de responsabilidades:
 - **Camada Cliente/Servidor (McpClient / McpServer)**: Ambos usam o **McpSession** para operações síncronas/assíncronas, com o **McpClient** gerenciando as operações de protocolo do lado do cliente e o **McpServer** gerenciando as operações de protocolo do lado do servidor.
- **Camada de Sessão (McpSession)**: Gerencia padrões de comunicação e estado usando a implementação *DefaultMcpSession*.
- **Camada de Transporte (McpTransport)**: Lida com a serialização/desserialização de mensagens **JSON-RPC** via:
 - **StdioTransport** (stdin/stdout) no módulo principal
 - Transportes **HTTP Server-sent Events (SSE)** em módulos de transporte dedicados (Java HttpClient, Spring WebFlux, Spring WebMVC)

Model Context Protocol (MCP) no Spring


- Conforme descrito, existem duas formas de criar um MCP server: via chamada Local (**StdioTransport**) ou (**HTTP-SSE**):




Model Context Protocol (MCP) no Spring

- O **Spring AI MCP** estende o MCP Java SDK com integração ao Spring Boot, fornecendo starters tanto para cliente quanto para servidor.
- **Starters de Cliente**
 - **spring-ai-starter-mcp-client**: Starter principal que oferece suporte a STDIO e SSE via HTTP.
 - **spring-ai-starter-mcp-client-webflux**: Implementação de transporte SSE baseada em WebFlux.
- **Starters de Servidor**
 - **spring-ai-starter-mcp-server**: Servidor principal com suporte para transporte STDIO.
 - **spring-ai-starter-mcp-server-webmvc**: Implementação de transporte SSE baseada em Spring MVC.
 - **spring-ai-starter-mcp-server-webflux**: Implementação de transporte SSE baseada em WebFlux.

Nossa arquitetura



Como Funciona?



Atenção – Verifique se seu Modelo suporta MCP



GPT-3.5 Turbo

Default



Legacy GPT model for cheaper chat and non-chat tasks

Modalities



Text

Input and output



Audio

Not supported



Image

Not supported

Endpoints



Chat Completions

v1/chat/completions



Realtime

v1/realtime



Batch

v1/batch



Embeddings

v1/embeddings



Image edit

v1/images/edits



Transcription

v1/audio/transcriptions



Moderation

v1/moderations



Responses

v1/responses



Assistants

v1/assistants



Fine-tuning

v1/fine-tuning



Image generation

v1/images/generations



Speech generation

v1/audio/speech



Translation

v1/audio/translations



Completions (legacy)

v1/completions

Features



Streaming

Not supported



Structured outputs

Not supported



Distillation

Not supported



Function calling

Not supported



Fine-tuning

Supported



Predicted outputs

Not supported



GPT-4.1

Default



Flagship GPT model for complex tasks

Modalities



Text

Input and output



Audio

Not supported



Image

Input only

Endpoints



Chat Completions

v1/chat/completions



Realtime

v1/realtime



Batch

v1/batch



Embeddings

v1/embeddings



Image edit

v1/images/edits



Transcription

v1/audio/transcriptions



Moderation

v1/moderations



Responses

v1/responses



Assistants

v1/assistants



Fine-tuning

v1/fine-tuning



Image generation

v1/images/generations



Speech generation

v1/audio/speech



Translation

v1/audio/translations



Completions (legacy)

v1/completions

Features



Streaming

Supported



Structured outputs

Supported



Distillation

Supported



Function calling

Supported



Fine-tuning

Supported



Predicted outputs

Supported

Tools

Tools supported by this model when using the Responses API.



Web search

Supported



Image generation

Supported



Computer use

Not supported



File search

Supported



Code interpreter

Supported



MCP

Supported

Vamos Criar um MCP server para o SIGAA

→ api.ufrn.br/servicos

BRASIL

Simplifique!

Comunica BR

Participe

Acesso à Informação

Legislação

Canais

UFRN

API.Sistemas
API de sistemas da UFRN

Alto contraste

Início

Documentação

Serviços

Publicações

Cadastre-se

Quem usa?

Exemplos

Suporte

Serviços

A API dispõe de um ambiente de testes que deverá ser usado durante o processo de desenvolvimento e o ambiente de produção que deverá ser usado após a homologação da sua aplicação. Endpoints e serviços no ambiente de SUSTENTAÇÃO podem sofrer alterações antes de ir para produção, ele se trata de um ambiente dinâmico e de validação. Na listagem abaixo poderá ser encontrada a documentação Swagger tanto dos serviços disponíveis no ambiente de SUSTENTAÇÃO, quanto os disponíveis no ambiente de PRODUÇÃO.

Ambiente de produção

Acao associada

Avaliacao institucional

Banca

Bem

Biblioteca

Bolsa apoio tecnico

Bolsista

Calendario

Capacitacao

Compra

Comum

Concurso

Contrato

Curriculo pesquisador

Curso

Discente

Docente

Docente externo

Ensino reele

Discente

discentes

Serviços para consulta das alterações realizadas na situação do discente

GET

/discentes

Retorna os discente que correspondam aos parâmetros informados.

GET

/discentes/{id-discente}

Retorna o discente do identificador passado.

GET

/discentes/{id-discente}/alteracoes-situacao

Retorna as alterações na situação do discente.

GET

/discentes/{id-discente}/carga-horaria

Retorna informações sobre a carga horária do discente conforme o identificador passado.

GET

/formas-ingresso

Retorna as formas de ingresso que correspondam aos parâmetros informados.

GET

/formas-ingresso/{id-forma-ingresso}

Retorna a forma de ingresso do identificador passado.

GET

/indices-discentes

Retorna os índices acadêmicos de discentes que correspondam aos parâmetros informados.

Vamos Criar um MCP Server

New Spring Starter Project

Service URL:

Name:

☒ Use default location

Location:

Type: Packaging:

Java Version: Language:

Group:

Artifact:

Version:

Description:

Package:

Working sets

☐ Add project to working sets New...

Working sets: Select...

? < Back Next > Finish Cancel

Vamos Criar um MCP Server

New Spring Starter Project Dependencies

Spring Boot Version: 3.5.0

Available:

- web

Selected:

- X Model Context Protocol Server
- X Spring Web

▼ Messaging

- ☐ WebSocket

▼ Template Engines

- ☐ Thymeleaf
- ☐ Apache Freemarker
- ☐ Mustache

▼ Testing

- ☐ Testcontainers

▼ Web

- ☒ Spring Web
- ☐ Spring Reactive Web
- ☐ Spring Web Services
- ☐ Jersey
- ☐ Vaadin

Make Default Clear Selection

? < Back Next > Finish Cancel

Definir a configuração

```
server:
  port: 8081
spring:
  application:
    name: sigaa-mcp-server
ai:
  mcp:
    server:
      stdio: false
      enabled: true
      type: SYNC
      name: sigaa-mcp-server
      version: 1.0.0
      capabilities:
        tool: true
        resource: false
        prompt: false
        completion: false
```

Definir os Tools

```
public class SigaaTools {  
    @Tool(name="verificarSeTemVagaEmTurma",  
    description = "Retorna a quantidades de vagas disponiveis de uma turma,"+  
    "quando o código da mesma é fornecido na forma de String")  
    String verificarSeTemVagaEmTurma(  
        @ToolParam(description = "é uma string na forma de: 3 caracteres seguido por 3 números") String c  
        {  
            System.out.println("Verificando vagas na turma " + codigoTurma);  
            if (codigoTurma.equals(anObject:"DIM0614")) {  
                return "A turma " + codigoTurma + " não tem vagas disponíveis.";  
            }else {  
                return "A turma " + codigoTurma + " tem 5 vagas disponíveis.";  
            }  
        }  
    }  
  
    @Tool(name="realizarMatriculadoAlunoNaTurma",  
    description = "Realiza a matrícula do(a) aluno(a) numa turma que tem vaga, dado que seja fornecido o  
    +"numero da matrícula do(a) aluno(a) e o código da turma como String")  
    String realizarMatriculaEmTurma(  
        @ToolParam(description = "é uma string no formato de 11 caracteres numericos")String matriculaAlu  
        String codigoTurma) {  
            System.out.println("Matriculando aluno " + matriculaAluno + " na turma " + codigoTurma);  
            return "O Aluno "+ matriculaAluno+ " foi matriculado na turma " + codigoTurma + " com sucesso! "  
                "A data da matricula foi " + LocalDateTime.now().format(java.time.format.DateTimeFormatte  
                .ofPattern(pattern:"dd/MM/yyyy HH:mm:ss", LocaleContextHolder.getLocale())) + ".";  
        }  
    }
```

Definir o Main...

```
@SpringBootApplication
public class SigaamcpserverApplication {

    Run | Debug
    public static void main(String[] args) {
        SpringApplication.run(primarySource:SigaamcpserverApplication.class, args);
    }

    @Bean
    public ToolCallbackProvider regSigaaTools(SigaaTools mcpServer) {
        return MethodToolCallbackProvider.builder().toolObjects(mcpServer).build();
    }

}
```

Vamos modificar o nosso cliente

```
<dependency>  
  <groupId>org.springframework.ai</groupId>  
  <artifactId>spring-ai-starter-mcp-client</artifactId>  
</dependency>
```

```
server:  
  port: 8080  
spring:  
  application.name: embedding-service  
  ai: ...  
---  
spring:  
  config.activate.on-profile: openai  
  ai:  
    openai: ...  
  mcp:  
    client:  
      toolcallback:  
        enabled: true  
      sse:  
        connections:  
          server:  
            stdio: false  
            url: http://localhost:8081  
            sse-endpoint: /sse  
            sse-message-endpoint: /mcp/messages
```

Vamos modificar o nosso Service

→ EmbeddingController | ← 5 beans

@Service

public class CursosServiceImpl implements CursosService {

private final CursosDAO cursosDAO;

private final DocumentReader documentReader;

@Autowired

VectorStore vectorStore;

ChatMemoryRepository chatMemoryRepository = new InMemoryChatMemoryRepository();

ChatMemory chatMemory = MessageWindowChatMemory.builder()

.chatMemoryRepository(chatMemoryRepository)

.maxMessages(maxMessages:10)

.build();

private final ChatClient chatClient;

@Value("classpath:prompt/promptUser.st")

Resource templateuser;

@Value("classpath:prompt/promptSystem.st")

Resource templatesystem;

← DocumentReader

public CursosServiceImpl(CursosDAO cursosDAO, DocumentReader documentReader,

ChatClient.Builder chatClientBuilderOpenAI, List<McpSyncClient> mcpClients) {

this.cursosDAO = cursosDAO;

this.documentReader = documentReader;

this.chatClient = chatClientBuilderOpenAI

.defaultToolCallbacks(new SyncMcpToolCallbackProvider(mcpClients))

.build();

}

Usando o MCP

← → ↻ ⓘ localhost:8080/consulta?pergunta=existe%20disponibilidade%20na%20turma%20DIM0640?&usuario=nelio

Sim, há 5 vagas disponíveis na turma DIM0640.

← → ↻ ⓘ localhost:8080/consulta?pergunta=faça%20minha%20matricula%20nessa%20turma%20por%20favor?&usuario=nelio

Sua matrícula na turma DIM0640 foi realizada com sucesso! A data da matrícula foi 04/06/2025 às 13:44:43.

← → ↻ ⓘ localhost:8080/consulta?pergunta=gostaria%20de%20me%20matricular%20numa%20turma?&usuario=ricardo 🔍 ☆ * 📁 👤 ⋮

Claro! Para prosseguirmos com a sua matrícula, preciso que você informe o número da matrícula e o código da turma na qual deseja se matricular. Por favor, forneça essas informações para que eu possa verificar se há vagas disponíveis.